Universidad Autónoma de Nuevo León

Facultad de Ciencias Físico Matemáticas

Introducción al Aprendizaje Automático Proyecto Intermedio: Predicción de Victorias en la NBA

Docente: Rafael Alfredo Cavazos Martínez

Integrantes:

Nombre	Matricula
Diego Andre Islas Cadillo	2132810
Mayela Mayte Lopez Cerino	1953581
Luis Daniel Ruiz Dorador	2132809

Fecha: 13 de marzo de 2026

i. Introducción

El presente proyecto aborda un problema de clasificación binaria en el dominio del baloncesto profesional (NBA). El objetivo consiste en predecir si un equipo ganó o perdió un partido a partir de sus estadísticas de rendimiento registradas durante el juego.

El conjunto de datos utilizado proviene de la plataforma Kaggle y contiene más de 144,000 registros históricos de equipos de la NBA, cada uno descrito por 48 variables originales. Para el modelado se seleccionaron 18 características numéricas representativas del rendimiento en cancha:

Categoría	Características
Localía	`home` (1 = local, 0 = visitante)
Tiros de campo	`fieldGoalsAttempted`, `fieldGoalsMade`, `fieldGoalsPercentage`
Triples	`threePointersAttempted`, `threePointersMade`, `threePointersPercentage`
Tiros libres	`freeThrowsAttempted`, `freeThrowsMade`, `freeThrowsPercentage`
Rebotes	`reboundsDefensive`, `reboundsOffensive`, `reboundsTotal`
Otros	`assists`, `blocks`, `steals`, `foulsPersonal`, `turnovers`

Dimensiones originales: (144614, 48)
Registros: 144,614 | Columnas: 48

	gameId	gameDateTimeEst	teamCity	teamName	teamId	opponentTeamCity	opponentTeamName	opponentTeamId	home	win	...	leadChanges	pointsFastBreak	pointsFromTurnovers	pointsInThePaint	pointsSecondChance	timesTied	timeoutsRemaining	seasonWins	seasonLosses	coachId
0	22500366	2025-12-08 15:00:00	New Orleans	Pelicans	1610612740	San Antonio	Spurs	1610612759	1	0	...	13.0	16.0	17.0	84.0	6.0	11.0	0.0	3.0	22.0	NaN
1	22500366	2025-12-08 15:00:00	San Antonio	Spurs	1610612759	New Orleans	Pelicans	1610612740	0	1	...	13.0	22.0	16.0	62.0	18.0	11.0	0.0	16.0	7.0	NaN
2	22500365	2025-12-08 14:30:00	Minnesota	Timberwolves	1610612750	Phoenix	Suns	1610612756	1	0	...	2.0	9.0	14.0	40.0	20.0	6.0	0.0	15.0	9.0	NaN
3	22500365	2025-12-08 14:30:00	Phoenix	Suns	1610612756	Minnesota	Timberwolves	1610612750	0	1	...	2.0	5.0	24.0	50.0	10.0	6.0	0.0	14.0	10.0	NaN
4	22500364	2025-12-08 14:00:00	Indiana	Pacers	1610612754	Sacramento	Kings	1610612758	1	1	...	4.0	12.0	17.0	34.0	11.0	6.0	0.0	6.0	18.0	NaN

Estadisticas descriptivas de las caracteristicas seleccionadas:

	home	assists	blocks	steals	fieldGoalsAttempted	fieldGoalsMade	fieldGoalsPercentage	threePointersAttempted	threePointersMade	threePointersPercentage	freeThrowsAttempted	freeThrowsMade	freeThrowsPercentage	reboundsDefensive	reboundsOffensive	reboundsTotal	foulsPersonal	turnovers	win
count	102551.0	102551.00	102551.00	102551.00	102551.00	102551.00	102551.00	102551.00	102551.00	102551.00	102551.00	102551.00	102551.00	102551.00	102551.00	102551.00	102551.00	102551.00	102551.0
mean	0.5	23.00	4.99	7.90	83.77	38.45	0.46	19.18	6.79	0.34	25.09	18.99	0.76	30.96	11.79	42.75	21.71	14.86	0.5
std	0.5	5.53	2.64	3.05	8.50	5.80	0.06	11.04	4.59	0.14	8.12	6.55	0.10	5.63	4.32	6.75	4.80	4.18	0.5
min	0.0	4.00	0.00	0.00	29.00	9.00	0.23	1.00	0.00	0.00	1.00	0.00	0.00	3.00	0.00	15.00	4.00	0.00	0.0
25%	0.0	19.00	3.00	6.00	78.00	34.00	0.42	11.00	3.00	0.26	19.00	14.00	0.69	27.00	9.00	38.00	18.00	12.00	0.0
50%	0.0	23.00	5.00	8.00	83.00	38.00	0.46	17.00	6.00	0.34	24.00	18.00	0.76	31.00	11.00	42.00	21.00	15.00	0.0
75%	1.0	27.00	7.00	10.00	89.00	42.00	0.50	26.00	10.00	0.43	30.00	23.00	0.83	35.00	14.00	47.00	25.00	18.00	1.0
max	1.0	52.00	23.00	27.00	130.00	68.00	0.70	70.00	29.00	1.00	80.00	61.00	1.00	60.00	44.00	81.00	52.00	40.00	1.0

Tras la limpieza de valores nulos, el dataset resultante cuenta con 102,551 registros perfectamente balanceados (50% victorias, 50% derrotas), lo cual elimina la necesidad de técnicas de re-muestreo y permite una evaluación directa y justa de los modelos.

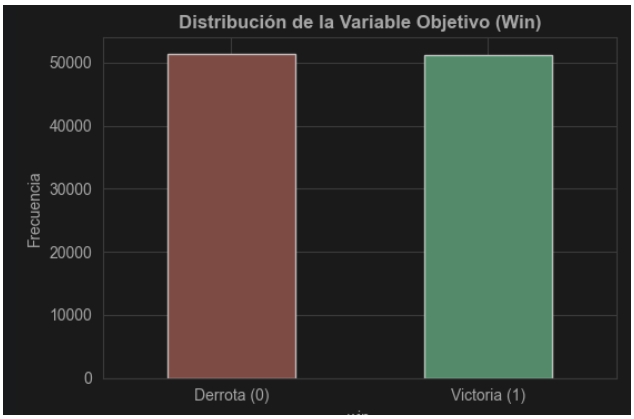

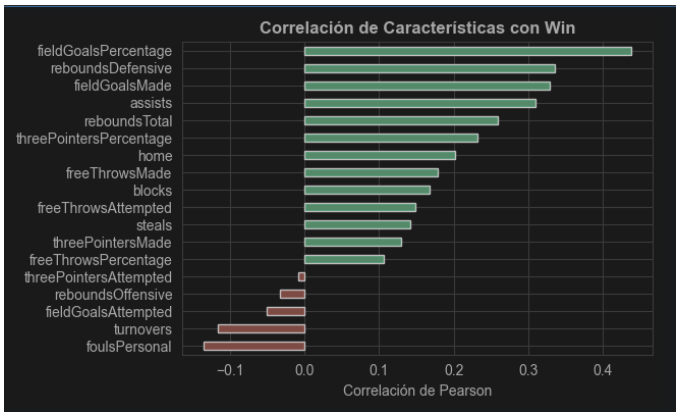

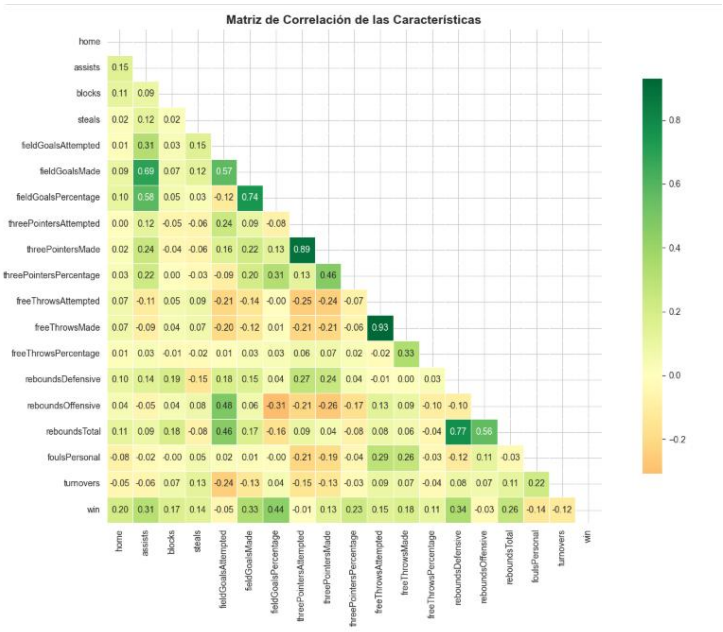

La variable objetivo es win (0 = derrota, 1 = victoria). Se busca identificar qué estadísticas de juego son los mejores predictores de victoria y comparar el rendimiento de tres algoritmos clásicos de aprendizaje supervisado.

ii. Descripción de los Modelos

a. K-Nearest Neighbors (KNN)

KNN es un algoritmo de aprendizaje supervisado clasificado como "perezoso" (lazy learner). A diferencia de otros métodos, KNN no construye un modelo interno durante la fase de entrenamiento;

simplemente almacena el conjunto de datos completo en memoria. La clasificación real ocurre en el momento de la predicción.

Funcionamiento: Cuando se presenta una nueva observación, KNN calcula la distancia entre ese punto y todos los puntos del conjunto de entrenamiento. Las métricas de distancia más comunes son:

- Distancia Euclidiana: $d(p,q) = \sqrt{\sum_{i=1}^{n}(p_i - q_i)^2}$
- Distancia de Manhattan: $d(p,q) = \sum_{i=1}^{n} |p_i - q_i|$

Luego selecciona los k vecinos más cercanos y asigna la clase mayoritaria entre ellos.

Efecto del hiperparámetro k:

- Un valor de **k pequeño** (ej. k=1 o k=3) genera fronteras de decisión muy complejas e irregulares, lo que hace al modelo altamente sensible al ruido y propenso al **sobreajuste (overfitting)**.
- Un valor de **k grande** produce fronteras más suaves pero puede llevar al **subajuste (underfitting)**, donde el modelo es incapaz de capturar patrones locales relevantes.

Ventajas:

- Fácil de implementar y entender.
- Versátil: funciona tanto para clasificación como para regresión.
- No requiere fase de entrenamiento explícita.

Desventajas:

- **Lento con datos masivos** en tiempo de predicción, ya que debe calcular distancias contra todo el dataset.
- Sufre severamente con **muchas dimensiones** (*maldición de la dimensionalidad*): en espacios de alta dimensión, las distancias tienden a uniformarse, perdiendo su capacidad discriminativa.
- Sensible a la escala de las variables (requiere normalización).

b. Árbol de Decisión

Los Árboles de Decisión son modelos que construyen una estructura jerárquica tipo árbol, dividiendo recursivamente los datos en subconjuntos cada vez más homogéneos, basándose en los valores de las características.

Criterios de división: En cada nodo, el algoritmo selecciona la característica y el umbral que mejor separa las clases. Los criterios más utilizados son:

- **Índice Gini:** Mide la **impureza** de un nodo. Un Gini de 0 significa que el nodo es completamente puro (una sola clase). Se calcula como: $Gini = 1 - \sum_{i=1}^{c} p_i^2$, donde p_i es la proporción de cada clase.
- **Ganancia de Información (Entropía):** Mide la reducción de incertidumbre al dividir. La entropía se calcula como: $H = -\sum_{i=1}^{c} p_i \log_2 (p_i)$. La división que maximiza la ganancia de información es la seleccionada.

Sobreajuste y Poda (Pruning): Los árboles de decisión son altamente propensos al sobreajuste si se les permite crecer sin restricciones. Un árbol sin límites memoriza el conjunto de entrenamiento, incluyendo su ruido. Para combatir esto, se aplican técnicas de poda como limitar la profundidad máxima (max_depth), establecer un número mínimo de muestras por hoja o un número mínimo de muestras para dividir.

Ventajas:

- **Fáciles de interpretar y visualizar**, lo que los hace ideales para comunicar resultados a stakeholders no técnicos.
- Baja necesidad de preprocesamiento: no requieren normalización ni estandarización.
- Manejan naturalmente variables categóricas y numéricas.

Desventajas:

- **Alta tendencia al sobreajuste** si no se controla la profundidad.

- Inestabilidad: pequeños cambios en los datos pueden producir árboles completamente diferentes.
- Fronteras de decisión ortogonales (paralelas a los ejes), lo que limita su flexibilidad.

c. Random Forest

Random Forest es un método de ensamble basado en Bagging (Bootstrap Aggregating) que combina las predicciones de múltiples árboles de decisión para obtener un resultado más robusto y preciso.

Funcionamiento:

1. Se generan **múltiples subconjuntos aleatorios** del dataset de entrenamiento mediante **muestreo con reemplazo (bootstrap)**.
2. Cada subconjunto se utiliza para entrenar un árbol de decisión independiente.
3. En cada nodo de cada árbol, solo se considera un **subconjunto aleatorio de características** (no todas), lo que introduce diversidad adicional entre los árboles.
4. La predicción final se determina por **votación mayoritaria** (en clasificación): cada árbol emite un voto y la clase con más votos gana.

Este doble mecanismo de aleatoriedad (en datos y en características) es clave para reducir la varianza del modelo.

Ventajas:

- **Reduce enormemente el riesgo de sobreajuste** de los árboles individuales al promediar sus predicciones.
- Alta precisión en la mayoría de problemas sin requerir un ajuste extensivo de hiperparámetros.
- **Robusto ante datos faltantes** y valores atípicos.
- Proporciona una medida de importancia de las características.

Desventajas:

- **Computacionalmente costoso:** requiere entrenar cientos de árboles, lo que implica mayor uso de memoria y tiempo.
- **Mayor tiempo de entrenamiento** comparado con modelos individuales.
- **Menor interpretabilidad** ("caja negra"): a diferencia de un solo árbol, no es posible visualizar fácilmente la lógica de decisión del bosque completo.

iii. Implementación y Resultados

a. Hiperparámetros Utilizados

Modelo	Hiperparámetro	Valor
KNN	`n_neighbors`	5
	`metric`	`minkowski` (p=2, equivalente a Euclidiana)
Árbol de Decisión	`max_depth`	5
	`criterion`	`gini`
	`random_state`	42
Random Forest	`n_estimators`	100
	`random_state`	42

Configuración de la división de datos:

- Entrenamiento: **80%** (82,040 registros)
- Prueba: **20%** (20,511 registros)
- random_state=42, con estratificación (stratify=y)

Se aplicó **StandardScaler** para normalizar las características, lo cual es esencial para el correcto funcionamiento de KNN (algoritmo sensible a la escala de las variables).

b. Tabla Comparativa de Resultados

Modelo	Accuracy	Recall	F1-Score	Tiempo de Entrenamiento (s)
KNN (k=5, Minkowski)	0.7847	0.7798	0.7833	0.003540
Árbol de Decisión (depth=5, Gini)	0.7436	0.7366	0.7413	0.174936
Random Forest (100 árboles)	**0.8232**	**0.8153**	**0.8214**	10.176229

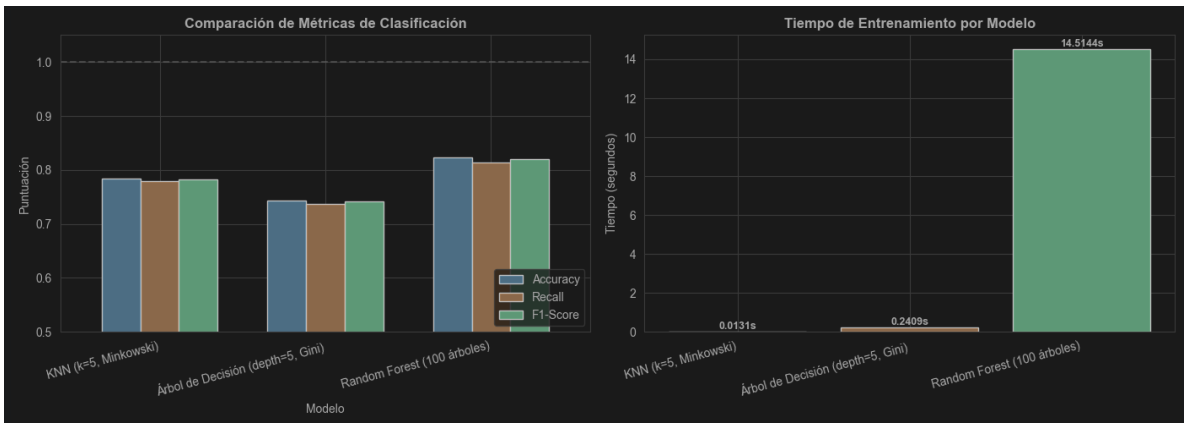

c. Matrices de Confusión

i. KNN (k=5, Minkowski)

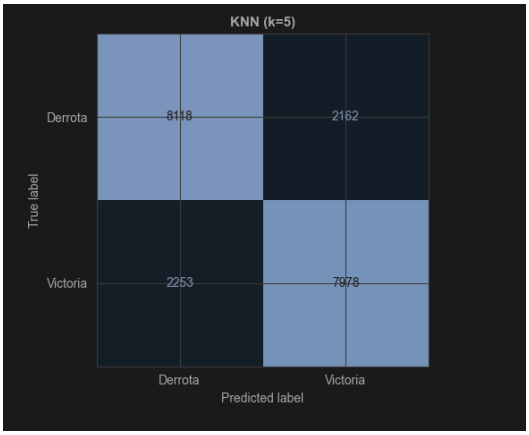

	Predicción: Derrota	Predicción: Victoria
Real: Derrota	8,118 (TN)	2,162 (FP)
Real: Victoria	2,253 (FN)	7,978 (TP)

ii. Árbol de Decisión (depth=5, Gini)

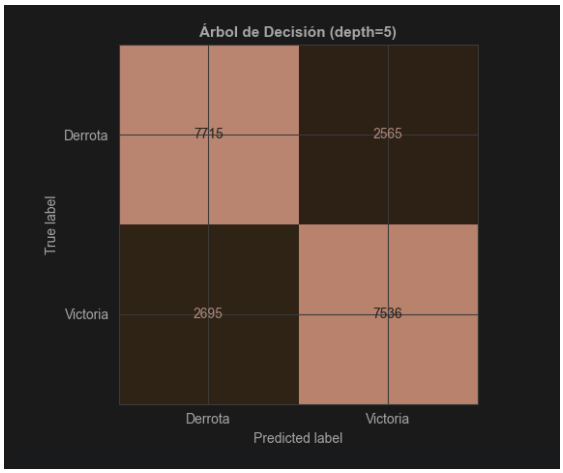

	Predicción: Derrota	Predicción: Victoria
Real: Derrota	7,715 (TN)	2,565 (FP)
Real: Victoria	2,695 (FN)	7,536 (TP)

iii. Random Forest (100 árboles)

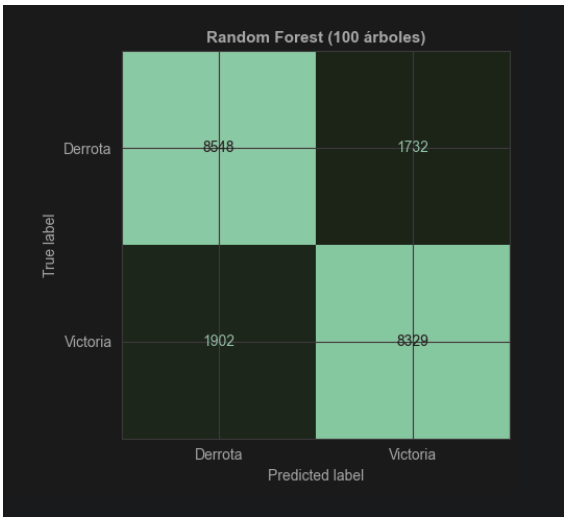

	Predicción: Derrota	Predicción: Victoria
Real: Derrota	8,544 (TN)	1,736 (FP)
Real: Victoria	1,890 (FN)	8,341 (TP)

d. Top 5 – Características más Importantes (Random Forest)

Característica	Importancia
`fieldGoalsPercentage`	0.1657
`reboundsDefensive`	0.0904
`reboundsTotal`	0.0759
`threePointersPercentage`	0.0665
`fieldGoalsMade`	0.0589

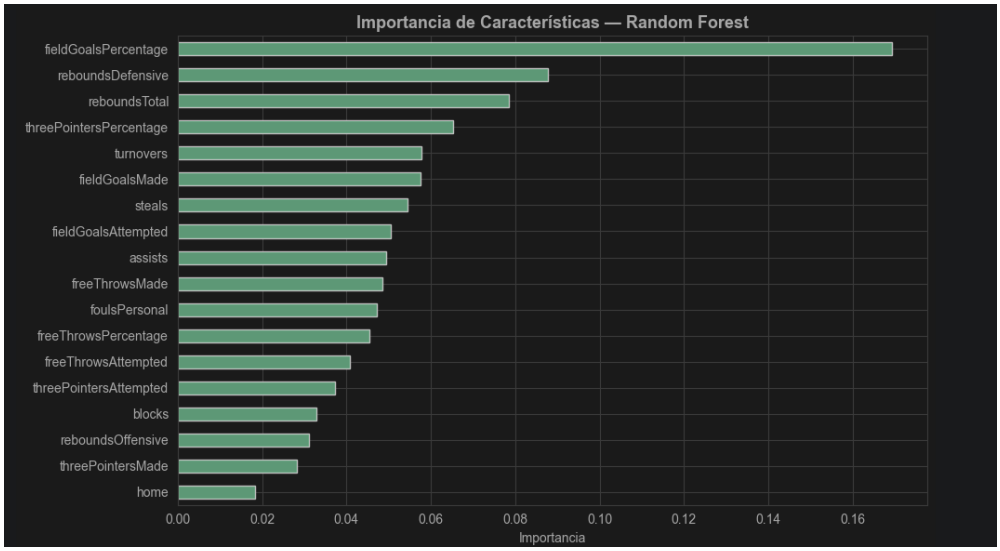

El porcentaje de tiros de campo (fieldGoalsPercentage) es, con amplio margen, la característica más influyente para predecir victorias, seguido de los rebotes defensivos y la efectividad en triples.

iv. Análisis y Conclusiones

a. Comparación de Desempeño

i. Precisión (Accuracy):

- Random Forest obtuvo la mejor precisión global con 82.32%, superando a KNN (78.47%) y al Árbol de Decisión (74.36%). Esto confirma que el método de ensamble logra generalizar mejor al combinar las predicciones de 100 árboles independientes.
- KNN se posiciona como el segundo mejor modelo, demostrando que la clasificación basada en similitud (vecinos cercanos) captura patrones relevantes en las estadísticas de juego.
- El Árbol de Decisión presenta el rendimiento más bajo, lo cual es esperado dada su limitación a una profundidad máxima de 5 niveles, que restringe su capacidad de capturar interacciones complejas entre las 18 características.

ii. Recall:

- Random Forest también lidera en recall (81.53%), lo que indica que identifica correctamente una mayor proporción de victorias reales. Esto es relevante porque minimiza los falsos negativos (victorias clasificadas como derrotas).
- KNN logró un recall de 77.98%, mientras que el Árbol de Decisión alcanzó 73.66%.

iii. F1-Score:

- El patrón se mantiene consistente: Random Forest (0.8214) > KNN (0.7833) > Árbol de Decisión (0.7413). El F1-score, al ser la media armónica entre precisión y recall, confirma que Random Forest ofrece el mejor equilibrio entre ambas métricas.

iv. Rapidez de Entrenamiento:

- KNN fue extremadamente rápido en entrenar (0.0035 s), lo cual es coherente con su naturaleza de "lazy learner": no realiza ningún cómputo durante el entrenamiento, solo almacena los datos. Sin embargo, es importante

notar que KNN transfiere su costo computacional a la predicción, donde debe calcular distancias contra todo el dataset para cada nueva observación.

- El Árbol de Decisión entrenó en 0.1749 s, un tiempo moderado que refleja la construcción de la estructura jerárquica.
- Random Forest tardó significativamente más (10.18 s), ya que debe construir y entrenar 100 árboles de decisión de forma independiente. Este mayor costo computacional es el precio que paga por su superior capacidad predictiva.

b. Análisis de las Matrices de Confusión

Las matrices de confusión revelan que:

- Random Forest tiene la menor cantidad de errores totales (3,626 errores vs. 4,415 de KNN y 5,260 del Árbol de Decisión).
- Los tres modelos muestran un comportamiento relativamente simétrico entre falsos positivos y falsos negativos, lo cual es consistente con el balance perfecto del dataset.

c. Aplicabilidad en Situaciones Reales

Criterio	KNN	Árbol de Decisión	Random Forest
Precisión	Media-Alta	Media	Alta
Rapidez (entrenamiento)	Muy rápida	Rápida	Lenta
Rapidez (predicción)	Lenta (escala mal)	Muy rápida	Rápida
Interpretabilidad	Baja	Muy alta	Baja
Escalabilidad	Baja	Alta	Media

i. KNN es más adecuado cuando:

- El dataset es de tamaño pequeño o mediano.
- Se necesita un prototipo rápido sin mucha configuración.
- El problema tiene pocas dimensiones (evita la maldición de la dimensionalidad).
- Ejemplo de negocio: Sistemas de recomendación en tiendas pequeñas donde se buscan productos "similares" a los que el cliente ya compró.

ii. Arboles de Decisión son más adecuados cuando:

- La interpretabilidad es crítica y los resultados deben ser explicados a stakeholders no técnicos (gerentes, médicos, reguladores).
- Se trabaja con datos mixtos (numéricos y categóricos) sin necesidad de preprocesamiento extensivo.
- Se requiere una solución rápida tanto en entrenamiento como en predicción.
- Ejemplo de negocio: Aprobación de créditos bancarios, donde las regulaciones exigen que las decisiones del modelo sean explicables y auditables.

iii. Random Forest es más adecuado cuando:

- La precisión máxima es la prioridad principal y se dispone de recursos computacionales suficientes.
- El dataset es grande y tiene muchas características.
- Se sospecha que existen interacciones complejas entre variables.
- Se necesita robustez ante datos ruidosos, valores atípicos o datos faltantes.
- Ejemplo de negocio: Predicción de resultados deportivos para casas de apuestas, detección de fraude financiero, o diagnóstico médico asistido donde la precisión puede salvar vidas.

d. Conclusión Final:

Para el problema específico de predecir victorias en la NBA a partir de estadísticas de juego, Random Forest es la opción óptima, logrando la mejor precisión (82.32%) a costa de un mayor tiempo de entrenamiento. Sin embargo, si el tiempo de respuesta en predicción fuera crítico (por ejemplo, en un sistema en tiempo real durante un juego), podría considerarse KNN como alternativa viable, siempre que se apliquen técnicas de optimización como KD-Trees o Ball-Trees para acelerar la búsqueda de vecinos. El Árbol de Decisión, aunque menos preciso, sería la elección ideal si se necesitara explicar las reglas de decisión a un cuerpo técnico o analistas deportivos de manera transparente.